UNIVERSIDADE FEDERAL DA FRONTEIRA SUL
CAMPUS CHAPECÓ
CURSO DE CIÊNCIA DA COMPUTAÇÃO

JEFFLEY GARÇON

PREVISÃO DE VAZÃO EM CENÁRIO DE MUDANÇAS CLIMÁTICAS: UMA ANÁLISE COMPARATIVA DE MODELOS LSTM E TEMPORAL FUSION TRANSFORMER NA BACIA DO RIO URUGUAI

CHAPECÓ
2026

JEFFLEY GARÇON

PREVISÃO DE VAZÃO EM CENÁRIO DE MUDANÇAS CLIMÁTICAS: UMA ANÁLISE COMPARATIVA DE MODELOS LSTM E TEMPORAL FUSION TRANSFORMER NA BACIA DO RIO URUGUAI

Trabalho de Conclusão de Curso apresentado ao Curso de Ciência da Computação da Universidade Federal da Fronteira Sul (UFFS), como requisito para obtenção do título de Bacharel em Ciência da Computação.

Orientador: Prof. Dr. Giancarlo Dondoni Salton
Co-Orientador: Prof. Dr. Fernando Grison

CHAPECÓ
2026

DEDICATÓRIA

Aos meus pais, Gesseline Dieujuste e Antonio Garçon, dedico cada página deste trabalho. Vocês me ensinaram que a educação e a dignidade são os bens mais preciosos que alguém pode possuir. O exemplo de perseverança e fé que vejo em vocês é o combustível que me impulsiona a ir além. Tudo o que sou e tudo o que espero ser, devo a vocês.

Aos meus irmãos, Jerry Garçon, Jhonsley Garçon e Jenhaelle Edwine Christy Garçon, dedico este momento com imenso carinho. A presença de vocês na minha vida é um presente diário, e saber que tenho o apoio e a torcida de vocês me dá a certeza de que nunca estarei sozinho nesta jornada.

“Não há conquista sem luta, e não há futuro sem enfrentar as mudanças do presente.”
(Anténor Firmin)

AGRADECIMENTOS

Primeiramente, elevo minha gratidão a Deus, por me conceder a vida, a saúde e a força necessária para persistir diante dos desafios e chegar até este momento de conquista.

Agradeço imensamente aos meus pais, Gesseline Dieujuste e Antonio Garçon, por todo o amor incondicional, pelos sacrifícios silenciosos e pelos ensinamentos que moldaram quem sou hoje. O apoio de vocês, mesmo à distância, foi o alicerce que me manteve firme. Aos meus irmãos, Jerry, Jhonsley e Jenhaelle, obrigado por serem meus amigos leais, pela torcida constante e por sempre acreditarem em mim.

Ao meu orientador, Prof. Dr. Giancarlo D. Salton, expresso meu profundo agradecimento pela orientação segura, pela paciência e pelas sugestões fundamentais que guiaram este trabalho.

Ao meu coorientador, Prof. Dr. Fernando Grison, agradeço imensamente pelo suporte técnico, pela disponibilidade e pelas contribuições valiosas que elevaram a qualidade desta pesquisa.

À minha namorada, Kettia Pierre, agradeço por todo o amor, pela compreensão nos momentos de estudo e por ser meu porto seguro. Sua presença e seu incentivo tornaram esta jornada muito mais especial.

À Universidade Federal da Fronteira Sul (UFFS), minha eterna gratidão por proporcionar uma educação pública, gratuita e de excelência, transformando minha trajetória pessoal e profissional.

Ao Setor de Assuntos Estudantis (SAE) da UFFS, pelo suporte fundamental para minha manutenção estudantil.

Um agradecimento especial ao Brasil, país que me acolheu, e a toda a comunidade pró-imigrante. Sou profundamente grato ao Programa Pró-Haiti e às políticas de inclusão da universidade. O apoio de vocês foi vital para minha permanência e êxito no ensino superior.

Aos meus amigos e companheiros de jornada, em especial ao meu amigo Wilvens Antoine (que iniciou esta caminhada universitária comigo), e aos amigos Angemydelson Saint-bert, Derson Jean, Djema Sime, Jaquet Leme, Jean Ivelsonne,

Linedy Saphira, Sebastien Lionel Lubin, Sodwin Dormelus, Wilsony Louis e Woodkensley Medeus. Obrigado pela amizade, pelo incentivo nos momentos difíceis e por compartilharem as alegrias desta etapa.

A todos os colegas da comunidade haitiana na UFFS, pela união e resistência. Que nossa presença aqui continue abrindo portas para os que virão.

A todos os professores do curso de Ciência da Computação, que compartilharam seus conhecimentos, e a todos que, de alguma forma, contribuíram para que eu pudesse realizar este sonho.

À Coordenação do Curso de Ciência da Computação e aos técnicos administrativos da UFFS, pelo suporte e paciência com as questões burocráticas ao longo da graduação.

Aos pesquisadores responsáveis pelo dataset CAMELS-BR, pela iniciativa de disponibilizar dados hidrológicos de qualidade, sem os quais esta pesquisa não seria possível.

A todos, meu muito obrigado!

RESUMO

A Bacia Hidrográfica do Rio Uruguai enfrenta desafios crescentes devido à não-estacionariedade hidrológica, impulsionada por mudanças climáticas e alterações no uso do solo. Modelos tradicionais de previsão de vazão, baseados em estacionariedade, tendem a apresentar desempenho reduzido em cenários de secas extremas. Este trabalho propõe uma análise comparativa entre duas arquiteturas de *deep learning* — LSTM (*baseline*) e *Temporal Fusion Transformer* (TFT) — para predizer a vazão média diária (horizonte de 1 dia à frente) em uma sub-bacia representativa da Bacia do Rio Uruguai. A metodologia segue o *framework* CRISP-DM, utilizando dados do conjunto CAMELS-BR (1980-2020), variáveis climáticas (precipitação, temperatura, evapotranspiração, índice ONI) e uma divisão temporal estratégica para avaliar a robustez dos modelos sob não-estacionariedade. Ambos os modelos serão implementados utilizando a biblioteca *PyTorch Forecasting*, garantindo paridade experimental. A hipótese central investigada é a de que o TFT, através de mecanismos de atenção interpretável e seleção de variáveis, apresentará maior estabilidade e menor degradação de erro que o LSTM durante rupturas hidrológicas e eventos de estiagem. O estudo busca contribuir para o desenvolvimento de sistemas de alerta precoce mais confiáveis, com impacto potencial na gestão hídrica, geração de energia e agroindústria no Sul do Brasil.

Palavras-Chave: Previsão de vazão, *Deep learning*, Não-estacionariedade climática, LSTM, Temporal Fusion Transformer, Bacia do Rio Uruguai..

ABSTRACT

The Uruguay River Basin faces increasing challenges due to hydrological non-stationarity driven by climate change and land-use alterations. Traditional streamflow forecasting models, based on stationarity, tend to exhibit reduced performance in extreme drought scenarios. This work proposes a comparative analysis between two deep learning architectures — LSTM (baseline) and Temporal Fusion Transformer (TFT) — to predict daily average streamflow (1-day ahead horizon) in a representative sub-basin of the Uruguay River. The methodology follows the CRISP-DM framework, using the CAMELS-BR dataset (1980-2020), climatic variables (precipitation, temperature, evapotranspiração, ONI index), and a strategic temporal split to assess robustness under non-stationarity. Both models will be implemented using the PyTorch Forecasting library to ensure experimental parity. The central hypothesis investigated is that the TFT, with interpretable attention mechanisms and variable selection, will exhibit greater stability and lower error degradation than LSTM during hydrological regime shifts and drought events. The study seeks to contribute to more reliable early warning systems, with potential impact on water management, hydropower generation, and agribusiness in southern Brazil.

Keywords: Streamflow forecasting, Deep learning, Non-stationarity, LSTM, Temporal Fusion Transformer, Uruguay River Basin..

SUMÁRIO

1 INTRODUÇÃO 9
1.1 QUESTÃO DE PESQUISA 10
1.2 OBJETIVOS 10
1.2.1 OBJETIVO GERAL 10
1.2.2 OBJETIVOS ESPECÍFICOS 10
1.3 JUSTIFICATIVA 11

2 FUNDAMENTAÇÃO TEÓRICA 13
2.1 MODELAGEM HIDROLÓGICA E NÃO-ESTACIONARIEDADE 13
2.2 PREVISÃO DE SÉRIES TEMPORAIS COM *DEEP LEARNING* 14
2.2.1 LONG SHORT-TERM MEMORY (LSTM) 14
2.3 TRANSFORMERS E INTERPRETABILIDADE 15
2.3.1 TEMPORAL FUSION TRANSFORMER (TFT) 15

3 TRABALHOS RELACIONADOS 17
3.1 PREVISÃO DE VAZÃO COM LSTM EM BACIAS BRASILEIRAS 17
3.2 APLICAÇÕES DE ARQUITETURAS *TRANSFORMER* NA HIDROLOGIA 18
3.3 ESTUDOS SOBRE A NÃO-ESTACIONARIEDADE HIDROLÓGICA NO BRASIL 19
3.4 POSICIONAMENTO E CONTRIBUIÇÃO DO PRESENTE TRABALHO . . . 20

4 METODOLOGIA 22

5 CRONOGRAMA 29

REFERÊNCIAS 30

1. INTRODUÇÃO

A Bacia Hidrográfica do Rio Uruguai desempenha um papel estratégico para a segurança energética e alimentar da Região Sul do Brasil. Seus afluentes respondem por uma parcela significativa da capacidade de geração hidrelétrica regional e sustentam uma agroindústria intensiva (MARCUZZO, 2017). No entanto, a gestão desses recursos enfrenta hoje um desafio estrutural: a validade dos dados históricos diante de um clima em transformação.

Historicamente, o planejamento de recursos hídricos baseou-se na hipótese de estacionariedade — a premissa de que as propriedades estatísticas das séries hidrológicas, como média e variância, oscilam dentro de um envelope fixo e previsível ao longo do tempo. Contudo, essa premissa tem sido desafiada pelo conceito de não-estacionariedade, amplamente discutido após o manifesto seminal de (MILLY et al., 2008). No contexto atual, a não-estacionariedade manifesta-se através de rupturas hidrológicas (*hydrological shifts*): mudanças abruptas no regime de vazão que alteram a distribuição de probabilidade dos eventos extremos, invalidando modelos calibrados exclusivamente em regimes passados.

A Bacia do Rio Uruguai é particularmente vulnerável a esse fenômeno. Estudos recentes, como o de (ROSA et al., 2022), indicam uma tendência de redução significativa na vazão média de diversos rios no Sul do Brasil, com sub-bacias apresentando quedas de vazão entre 15% e 30% após 1990. A gênese dessa alteração é multifatorial, impulsionada pela interação entre mudanças climáticas globais e alterações regionais no uso do solo. Além disso, a variabilidade hidrológica local é fortemente modulada por teleconexões climáticas, especificamente o *El Niño-Southern Oscillation* (ENSO).

Para capturar essa complexidade, a modelagem moderna deve incorporar indicadores climáticos robustos. Este trabalho utiliza o Índice Oceânico Niño (ONI), o principal indicador da NOAA (*National Oceanic and Atmospheric Administration*) para monitorar o ENSO, definido pela média móvel trimestral das anomalias da temperatura da superfície do mar no Pacífico Equatorial. A inclusão do ONI visa permitir que os modelos identifiquem padrões de variabilidade que antecedem eventos de seca ou cheia.

Diante desse cenário de incerteza física, surge a necessidade de avaliar se ferramentas de Inteligência Artificial, como o *Deep Learning*, oferecem maior resiliência do que abordagens tradicionais. A questão central não é apenas prever a vazão,

mas garantir que os modelos mantenham sua acurácia mesmo quando as regras do sistema hidrológico sofrem alterações.

1.1 Questão de Pesquisa

Este trabalho procura preencher uma lacuna na validação de modelos preditivos sob condições de mudança climática, buscando responder à seguinte questão:

> *Em que medida a arquitetura Temporal Fusion Transformer (TFT), por meio de seus mecanismos de atenção, apresenta maior robustez que a Long Short-Term Memory (LSTM) na previsão de vazão de curto prazo ($t + 1$) e na detecção de eventos de seca em bacias hidrográficas sujeitas à não-estacionariedade?*

1.2 Objetivos

1.2.1 Objetivo Geral

Investigar quantitativamente a robustez de arquiteturas de *Deep Learning* frente à não-estacionariedade climática, comparando o desempenho do TFT e do LSTM na previsão de vazão diária e na identificação de períodos de estiagem na Bacia do Rio Uruguai.

1.2.2 Objetivos Específicos

1. Estruturar um conjunto de dados hidrometeorológicos integrado, unificando séries do *dataset* CAMELS-BR com índices climáticos globais (ONI).
2. Quantificar o impacto da não-estacionariedade na acurácia preditiva, mensurando a degradação de desempenho de modelos treinados em regimes históricos (1980-1990) quando aplicados a cenários climáticos recentes (pós-1991).
3. Implementar as arquiteturas LSTM (*baseline*) e TFT em ambiente padronizado (*PyTorch*), configurando a saída para previsão probabilística de quantis.

4. Avaliar a capacidade dos modelos na identificação de eventos extremos de estiagem, utilizando métricas específicas para vazões mínimas (*Log-NSE*) e análise de limiar de seca (Q_{90}).

1.3 Justificativa

A Bacia Hidrográfica do Rio Uruguai constitui um pilar fundamental para o desenvolvimento socioeconômico da Região Sul do Brasil. Segundo (MARCUZZO, 2017), o sistema hidrológico da região é vital para a matriz energética nacional, com usinas que representam parcela significativa da geração hidrelétrica do subsistema Sul, além de sustentar uma agroindústria sensível à disponibilidade hídrica. Nesse contexto, a precisão na previsão de vazões não é apenas uma questão técnica, mas um requisito para a segurança energética e alimentar.

Tradicionalmente, a gestão desses recursos fundamentou-se na premissa da estacionariedade, assumindo que o padrão histórico de chuvas e vazões se manteria constante no futuro. Contudo, evidências recentes indicam uma ruptura nesse paradigma. Estudos como o de (ROSA et al., 2022) demonstram que a vazão de rios estratégicos no Sul do Brasil apresenta tendências de redução estatisticamente significativas nas últimas décadas, fenômeno associado tanto a forçantes climáticas quanto a mudanças no uso do solo.

Diante desse cenário de incerteza, modelos preditivos calibrados com séries históricas antigas correm o risco de obsolescência. Este trabalho justifica-se pela necessidade de mensurar objetivamente esse risco. A escolha do marco temporal de 1991 para a divisão dos dados não é aleatória; ela alinha-se às diretrizes da Organização Meteorológica Mundial (Organização Meteorológica Mundial (OMM), 2017), que define períodos de 30 anos para o estabelecimento de normais climatológicas, permitindo isolar um “regime passado” de um “regime recente” acelerado pelas mudanças climáticas.

Além do diagnóstico do problema, a pesquisa propõe uma investigação sobre a adequação de novas tecnologias. Enquanto modelos tradicionais e redes recorrentes simples (LSTM) podem apresentar limitações em capturar dinâmicas não-lineares sob mudança de regime, a literatura recente (AMANAMBU; MOSSA; CHEN, 2022; LIM et al., 2021) sugere que arquiteturas baseadas em *Transformers* oferecem maior robustez. O *Temporal Fusion Transformer* (TFT), em particular, destaca-se teoricamente por sua capacidade de interpretar a importância variável de *inputs* ao longo do

tempo. Testar se essa vantagem teórica se traduz em ganho real de performance na previsão de secas no Brasil é a lacuna que este estudo visa preencher.

2. FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta a revisão da literatura que fundamenta a presente pesquisa. A estrutura parte do contexto amplo das mudanças climáticas e seu impacto quantitável na hidrologia, progredindo para as ferramentas de *deep learning* utilizadas na previsão de séries temporais.

2.1 Modelagem Hidrológica e Não-Estacionariedade

A modelagem hidrológica constitui uma ferramenta fundamental para a gestão de recursos hídricos, pois possibilita a simulação e a previsão do comportamento de sistemas complexos, como bacias hidrográficas. No caso da Bacia do Rio Uruguai, sistema transfronteiriço de relevância para a agroindústria e para o setor de geração hidrelétrica no Sul do Brasil, a previsão de vazões com níveis adequados de acurácia representa um elemento central para o planejamento energético e para a segurança hídrica regional (MARCUZZO, 2017).

Historicamente, tanto os modelos conceituais baseados em processos físicos quanto os modelos estatísticos orientados por dados foram desenvolvidos sob a premissa de que o sistema hidrológico é estacionário. A estacionariedade pressupõe que os mecanismos que governam a dinâmica fluvial permanecem constantes ao longo do tempo. Do ponto de vista técnico, implica que propriedades estatísticas de séries históricas de vazão — como média, variância e padrões sazonais — mantêm-se estáveis ou previsíveis.

Esse pressuposto, entretanto, vem sendo invalidado por evidências empíricas. A não-estacionariedade não é apenas uma hipótese teórica, mas uma realidade quantificável na região de estudo. Análises recentes sobre a dinâmica hidrológica no Sul do Brasil, como as conduzidas por (ROSA et al., 2022), apontam para uma retração sistemática na disponibilidade hídrica. Em sub-bacias do Rio Uruguai, observou-se uma redução na vazão média anual da ordem de 15% a 25% nas últimas três décadas, exacerbada por eventos de seca mais frequentes e severos.

Essa magnitude de variação desafia a calibração de modelos tradicionais, pois altera as curvas de permanência e a relação chuva-vazão, sugerindo que parâmetros ajustados em décadas passadas podem subestimar a severidade das estiagens atuais. Além dessas tendências de longo prazo, a variabilidade interanual é fortemente modulada por fenômenos climáticos de grande escala, como o *El Niño-Southern Os-*

cillation (ENSO), monitorado através do Índice Oceânico Niño (ONI) (NOAA Climate Prediction Center, 2025).

Nesse contexto, torna-se necessário que a modelagem hidrológica incorpore abordagens capazes de lidar com a não-estacionariedade. A literatura recente indica que métodos baseados em *machine learning* oferecem um conjunto de técnicas promissoras para esse propósito, permitindo capturar não-linearidades complexas que modelos físicos simplificados muitas vezes não representam adequadamente (REICHSTEIN et al., 2021).

2.2 Previsão de Séries Temporais com *Deep Learning*

A presença de não-estacionariedade impõe desafios relevantes aos modelos hidrológicos tradicionais, que frequentemente se apoiam em premissas lineares. Nesse cenário, abordagens orientadas por dados (*data-driven*) têm adquirido destaque, impulsionadas pela disponibilidade de extensos conjuntos de dados — como o *CAMELS-BR* (CHAGAS et al., 2020) — e pelo avanço do poder computacional.

Ressalta-se que o uso do *CAMELS-BR* padroniza a entrada de dados e facilita a reprodutibilidade científica. Embora o uso de dados pré-processados possa abstrair certas particularidades locais, a consistência deste *dataset* já foi validada em diversos estudos hidrológicos nacionais, permitindo focar a análise na arquitetura dos modelos preditivos.

2.2.1 Long Short-Term Memory (LSTM)

Segundo (HOCHREITER; SCHMIDHUBER, 1997), embora as *Recurrent Neural Networks* (RNNs) sejam redes utilizadas para modelar séries temporais, elas apresentam dificuldades para aprender dependências de longo prazo devido ao problema do desaparecimento de gradiente. Para mitigar essa limitação, foi proposta a arquitetura *Long Short-Term Memory* (LSTM).

O LSTM constitui um tipo especializado de RNN que emprega uma estrutura interna composta por células de memória e mecanismos de controle denominados *gates* (portões), responsáveis por regular o fluxo de informação. Essa estrutura é composta por três mecanismos principais:

1. Forget gate (f_t): decide qual parcela da memória anterior deve ser descartada.

2. Input gate (i_t): controla a incorporação de novas informações à célula de memória.
3. Output gate (o_t): determina qual parte do estado interno será utilizada para compor a saída.

Formalmente, o *forget gate* é definido por:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \tag{2.1}$$

A capacidade de preservar e manipular informações ao longo de sequências extensas torna a arquitetura LSTM adequada para aplicações hidrológicas. Estudos realizados no contexto brasileiro, como (DONINELLI et al., 2017), validaram seu uso na Bacia do Rio Apuaê (sub-bacia do Uruguai), estabelecendo-o como um *baseline* robusto para a região.

2.3 Transformers e Interpretabilidade

Embora o LSTM represente um avanço, sua natureza intrinsecamente sequencial limita a eficiência computacional e a capacidade de estabelecer relações diretas entre eventos muito distantes no tempo. Para superar isso, a arquitetura *Transformer* (VASWANI et al., 2017) introduziu o mecanismo de *self-attention* (autoatenção), que permite ao modelo considerar simultaneamente todos os elementos de uma sequência, ponderando a importância de cada ponto temporal passado para a previsão atual.

2.3.1 Temporal Fusion Transformer (TFT)

Para adaptar o poder dos *Transformers* às especificidades de séries temporais multivariadas, (LIM et al., 2021) propuseram o *Temporal Fusion Transformer* (TFT). Esta arquitetura híbrida combina a capacidade de aprendizado sequencial de camadas LSTM com a visão global dos mecanismos de atenção.

Uma crítica recorrente à aplicação de *Deep Learning* na hidrologia refere-se à natureza “caixa-preta” (*black-box*) das redes neurais, onde o processo de decisão é opaco. O TFT foi projetado especificamente para mitigar essa limitação através de componentes de interpretabilidade intrínseca:

- Variable Selection Networks: Selecionam automaticamente quais variáveis de entrada (ex: precipitação, evapotranspiração, ONI) são mais relevantes para a previsão em cada passo de tempo, descartando ruídos.
- Interpretable Multi-Head Attention: Permite visualizar os “pesos de atenção”, indicando em quais momentos do passado o modelo focou para gerar a previsão atual (ex: identificando se o modelo está reagindo a uma chuva de ontem ou a um padrão sazonal de meses atrás).

Essa capacidade de interpretação responde à necessidade de transparência na modelagem hidrológica, permitindo verificar se o modelo está aprendendo relações fisicamente coerentes ou apenas correlações espúrias (REICHSTEIN et al., 2021). Estudos recentes confirmam a superioridade dessa abordagem para previsão de extremos hidrológicos (AMANAMBU; MOSSA; CHEN, 2022; FAYER et al., 2023).

3. TRABALHOS RELACIONADOS

Neste capítulo, são analisados os trabalhos mais próximos à presente pesquisa, com o objetivo de contextualizar a abordagem proposta e destacar sua contribuição original para a literatura. A investigação está dividida em estudos que aplicam modelos de *deep learning* para a previsão hidrológica no Brasil e em trabalhos que investigam a não-estacionariedade, resultando na síntese que representa essa pesquisa.

3.1 Previsão de Vazão com LSTM em Bacias Brasileiras

A aplicação de redes neurais *Long Short-Term Memory (LSTM)* para a previsão de vazão no Brasil já foi validada em diversos estudos que demonstram a robustez da arquitetura para as condições hidrológicas do país. Esses trabalhos servem como um ponto de partida e uma base de comparação para a presente pesquisa.

Um exemplo de particular relevância para este trabalho é o estudo de (DONINELLI et al., 2017). Os autores realizaram uma análise na Bacia do Rio Apuaê, uma importante sub-bacia do Rio Uruguai, utilizando uma arquitetura LSTM para prever vazões diárias a partir de dados históricos de vazão e precipitação, cobrindo o período de 1976 a 2016. O estudo não apenas confirmou a superioridade do LSTM em relação a modelos mais simples, mas também validou sua eficácia para a região hidrográfica de interesse desta pesquisa. No entanto, é importante notar que o trabalho de (DONINELLI et al., 2017) operou sob a premissa de estacionariedade, utilizando a totalidade da longa série histórica para o treinamento, sem investigar se a performance do modelo seria degradada por mudanças no regime climático ao longo desse extenso período. Essa é, portanto, a primeira lacuna que este trabalho se propõe a endereçar: o teste de robustez do LSTM em um cenário de não-estacionariedade comprovada.

Outros estudos em diferentes bacias brasileiras seguem uma abordagem metodológica semelhante, focando na otimização da arquitetura do LSTM e na comparação de sua performance com outros modelos de machine learning e estatísticos. Em geral, esses trabalhos corroboram a capacidade do LSTM de capturar as complexas relações não-lineares do processo chuva-vazão. O que une a maioria desses estudos é o foco na acurácia preditiva dentro de um único regime de dados, tratando a série histórica como um bloco homogêneo. A contribuição do presente trabalho, portanto, não é questionar a eficácia do LSTM, mas sim investigar a robustez de sua per-

formance quando confrontado com a hipótese de não-estacionariedade, um aspecto ainda pouco explorado na literatura aplicada a bacias brasileiras.

3.2 Aplicações de Arquiteturas *Transformer* na Hidrologia

Com o melhoramento da arquitetura *Transformer*, a pesquisa em previsão de séries temporais hidrológicas tem explorado seu potencial para superar as limitações de modelos puramente sequenciais. O *Temporal Fusion (TFT)*, em particular, não é um *transformer* puro, mas sim uma arquitetura híbrida, projetada especificamente para a previsão de séries temporais multivariadas (LIM et al., 2021). Diversos trabalhos recentes validam a relevância e a superioridade desta abordagem no contexto hidrológico.

Um estudo comparativo de grande relevância foi conduzido por (AMANAMBU; MOSSA; CHEN, 2022), que avaliou um modelo baseado em *Transformer* contra um LSTM para a tarefa de previsão de seca hidrológica em uma bacia nos Estados Unidos. O trabalho concluiu que, embora ambos os modelos tivessem bom desempenho, o modelo *Transformer* obteve uma performance superior, especialmente na previsão de eventos de baixa vazão, reforçando a relevância desta arquitetura para o problema central desta pesquisa: a previsão de secas. Contudo, o estudo foca na comparação direta de arquiteturas, mas não implementa um desenho experimental para medir o impacto de dados de treino temporalmente obsoletos — a lacuna de teste de estresse temporal que esta pesquisa propõe.

No contexto brasileiro, a aplicação do TFT foi validada por (FAYER et al., 2023) para a previsão de afluência em um reservatório hidroelétrico no sudeste do Brasil. Este estudo é de grande importância por ser uma das primeiras validações do TFT em um caso de uso real no país. Os autores destacaram a capacidade do modelo de lidar com diferentes tipos de variáveis e sua performance superior a modelos de *baseline* como o AutoARIMA e o *DeepAR*. O trabalho de (FAYER et al., 2023) não apenas confirma a adequação do TFT para problemas hidrológicos no Brasil, mas também serve como precedente metodológico para a sua aplicação. Todavia, assim como os demais, o estudo valida o TFT em um único regime climático, buscando otimizar a previsão. Ele não questiona a validade dos dados de treino, deixando em aberto a lacuna de como a não-estacionariedade impacta a performance deste modelo, ponto central desta pesquisa.

A análise destes trabalhos relacionados demonstra duas tendências claras: (1) modelos baseados em *Transformer* estão se mostrando mais robustos que o LSTM

para a previsão de eventos hidrológicos extremos, como secas; e (2) a arquitetura TFT já foi aplicada com sucesso no cenário brasileiro. Estas descobertas, em conjunto, fornecem uma forte justificativa para a escolha do TFT como o modelo avançado a ser investigado nesta pesquisa e para a comparação direta de seu desempenho com o do LSTM.

Um dos estudos comparativos mais abrangentes até o momento foi conduzido por (KOYA; ROY, 2024), que testou o desempenho do LSTM, de um *Transformer* puro e do *Temporal Fusion Transformer* (TFT) em 2.610 bacias de escala global. O objetivo central do trabalho foi testar a hipótese de que a arquitetura híbrida do TFT, ao combinar a recorrência do LSTM com os mecanismos de atenção do *Transformer*, apresentaria melhor desempenho. Os resultados confirmaram a hipótese, com o TFT superando consistentemente os outros dois modelos na previsão de vazão. Este estudo fornece uma forte justificativa metodológica para a comparação direta entre essas três classes de arquiteturas e para a seleção do TFT como o modelo mais avançado.

3.3 Estudos sobre a Não-Estacionariedade Hidrológica no Brasil

A premissa central que motiva a presente pesquisa — a de que os modelos de previsão precisam ser reavaliados em um cenário de mudanças climáticas — é diretamente suportada por uma robusta linha de investigação focada na detecção de alterações nos regimes hidrológicos do Brasil. Estes estudos fornecem a evidência empírica de que a não-estacionariedade não é uma hipótese teórica, mas um fenômeno observado e em andamento.

Um trabalho de fundamental importância neste contexto é o de (CHAGAS; CHAFFE; BLöSCHL, 2022), publicado na *Nature Communications*. Em uma análise de larga escala, os autores investigaram séries de vazão de 886 estações hidrométricas em todo o Brasil para avaliar como o ciclo da água respondeu às pressões climáticas e de uso do solo nas últimas quatro décadas. As conclusões do estudo são inequívocas: os efeitos combinados das mudanças climáticas e do de vazão. O estudo identificou que 29% da área estudada, incluindo a região sul da Amazônia, está passando por uma aceleração do ciclo hidrológico, com secas e cheias se tornando mais severas.

Este achado é a prova científica que fundamenta a principal questão de pesquisa deste estudo. Enquanto o trabalho de (CHAGAS; CHAFFE; BLöSCHL, 2022) se concentra em detectar e atribuir as causas da não-estacionariedade, ele não explora a consequência direta desse fenômeno para a prática da modelagem preditiva. Ou seja, ele confirma que as regras do sistema mudaram, mas não mede o impacto dessa

mudança na performance de modelos de *deep learning* que foram treinados sob as regras antigas.

Tabela 3.1 – Síntese Comparativa dos Trabalhos Relacionados

Autor (Ano)	**Método / Contexto**	**Resultado Chave**	**Limitação**
Doninelli et al. (2017)	**LSTM** Bacia do Rio Uruguai (ANA)	Valida o LSTM como eficaz para a região hidrográfica de estudo.	Assume estacionariedade e não testa impacto de mudanças climáticas.
Lim et al. (2021)	**TFT** Benchmark Teórico	Propõe a arquitetura TFT para séries temporais multivariadas complexas.	Foco na arquitetura geral, sem validação específica na hidrologia brasileira.
Amanambu et al. (2022)	**Transformer vs. LSTM** Bacias USGS (EUA)	Demonstra que Transformers superam LSTM na previsão de secas.	Foca na comparação de modelos, mas não no impacto da obsolescência dos dados.
Fayer et al. (2023)	**TFT vs. Baselines** Reservatório (Brasil)	Valida o TFT no Brasil com performance superior ao ARIMA/DeepAR.	Aplicação em regime único, sem realizar o "teste de estresse"temporal.
Koya & Roy (2024)	**TFT (Híbrido)** Estudo Global	Confirma que o TFT supera tanto LSTM quanto Transformer puro.	Análise global de média, sem foco na degradação por não-estacionariedade local.
Chagas et al. (2022)	**Análise Estatística** CAMELS-BR	Comprova fisicamente a não-estacionariedade nos rios brasileiros.	Diagnostica o problema físico, mas não avalia o impacto nos modelos de IA.

Fonte: Elaborado pelo autor (2025).

3.4 Posicionamento e Contribuição do Presente Trabalho

A análise dos trabalhos relacionados permite posicionar a presente pesquisa em uma intersecção única. Enquanto (DONINELLI et al., 2017) validam o LSTM localmente e (FAYER et al., 2023) demonstram o potencial do TFT no Brasil, nenhum estudo implementa um desenho experimental para medir explicitamente o impacto da não-estacionariedade diagnosticada por (CHAGAS; CHAFFE; BLöSCHL, 2022) na confiabilidade dessas ferramentas.

A contribuição original reside na proposição de uma metodologia para quantificar o risco de utilizar dados históricos em um cenário climático alterado. Ao comparar modelos treinados com dados antigos (1980-1990) contra modelos atualizados (pós-1991), este trabalho preenche a lacuna entre a detecção do problema físico e a validação das ferramentas computacionais, oferecendo uma análise crítica sobre a validade das práticas de modelagem preditiva atuais.

4. METODOLOGIA

A presente pesquisa será conduzida com base na metodologia *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*), um *framework* amplamente utilizado na área de ciência de dados por organizar o processo analítico em seis fases inter-relacionadas. Essa abordagem foi selecionada por oferecer uma estrutura sistemática que orienta desde a formulação inicial do problema até a comunicação final dos resultados, permitindo, ao mesmo tempo, a flexibilidade necessária para o desenvolvimento incremental da investigação (CHAPMAN et al., 2000).

A fase de Entendimento da Pesquisa envolveu a formulação do problema associado à não-estacionariedade climática e seus impactos na previsão de vazões na Bacia Hidrográfica do Rio Uruguai. Sua relevância decorre da crescente evidência de que o comportamento hidrológico brasileiro se encontra em transformação, o que compromete a adequação de modelos treinados integralmente com dados históricos (ROSA et al., 2022). As questões de pesquisa foram delineadas para avaliar a perda de desempenho de modelos de *deep learning* treinados sob diferentes regimes climáticos, bem como comparar o comportamento das arquiteturas *Long Short-Term Memory* (LSTM) e *Temporal Fusion Transformer* (TFT).

A etapa de Entendimento dos Dados contemplará a coleta e análise das fontes primárias de informação. Serão utilizados o *dataset* CAMELS-BR, que reúne séries de vazão e variáveis meteorológicas (CHAGAS et al., 2020), e o Índice Oceânico Niño (ONI), divulgado pela NOAA. A área de estudo será caracterizada com base em referências como Marcuzzo (2017), que descrevem a formação da bacia pela confluência dos rios Pelotas e Canoas e sua importância operacional para os setores agroindustrial e hidrelétrico. Em seguida, será realizada uma filtragem programática para identificar sub-bacias com séries temporais completas e selecionar uma unidade representativa para a execução da Análise Exploratória de Dados (EDA). A estação fluviométrica de referência será definida nesta etapa de seleção da sub-bacia, priorizando postos com baixas falhas e localizados na exutória da unidade hidrográfica.

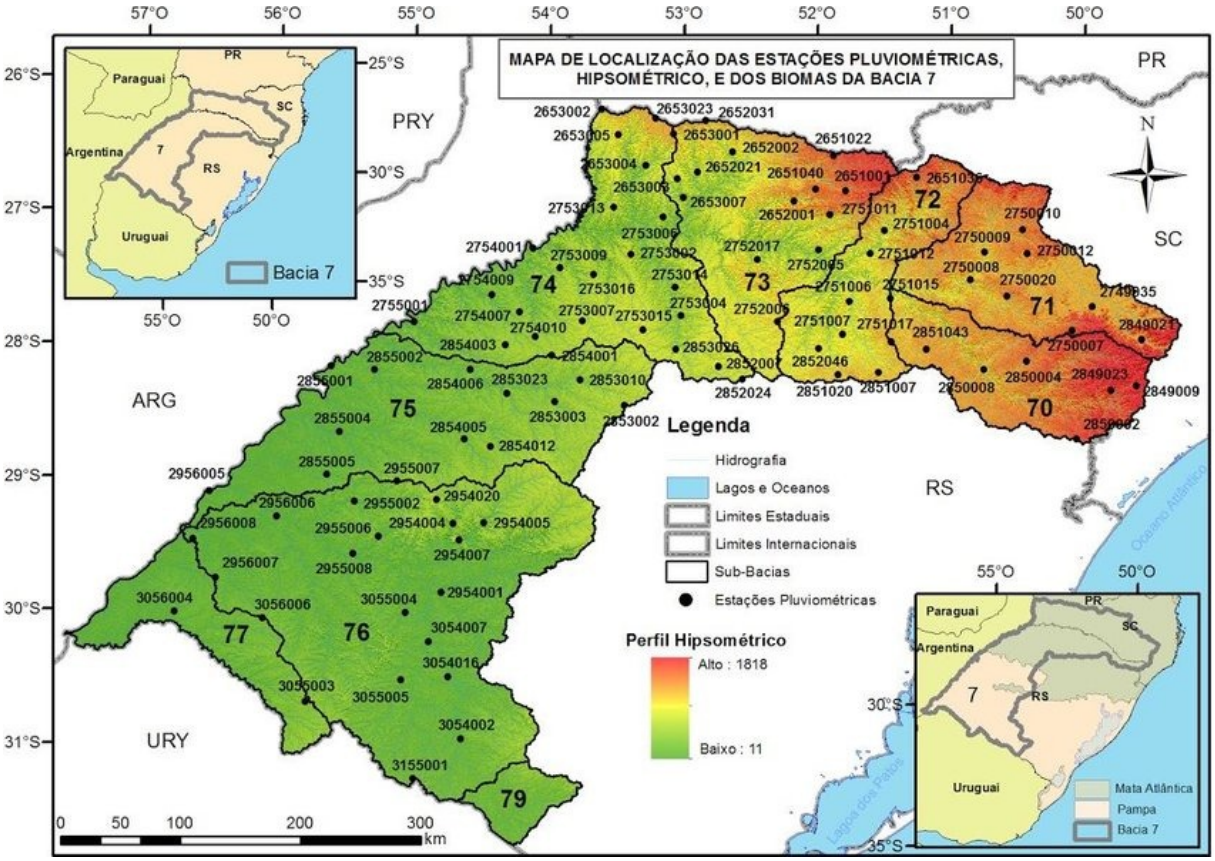

Figura 4.1 – Mapa da Bacia Hidrográfica do Rio Uruguai. Nota: A delimitação final considerará a bacia física (divisora de águas), independente de fronteiras políticas.

A escolha dessa sub-bacia representativa, a ser realizada na etapa inicial do TCC 2, seguirá critérios técnicos destinados a assegurar a validade experimental e evitar vieses decorrentes de escolhas arbitrárias. A seleção considerará a extensão e continuidade da série histórica, a disponibilidade dos atributos estáticos necessários à arquitetura *TFT* e a representatividade hidrológica da unidade, com preferência por bacias de porte intermediário e menos sujeitas a intervenções antrópicas intensas.

Após essa etapa, a fase de Preparação dos Dados transformará as séries brutas em um formato adequado para a modelagem. Os dados selecionados serão unificados em um único *DataFrame*, seguido da aplicação de técnicas de engenharia de atributos. Variáveis temporais de natureza cíclica, como o mês do ano, serão convertidas para representações contínuas por meio das funções seno e cosseno, conforme as equações abaixo, prática consolidada em *deep learning* para preservar relações de proximidade ao longo do ciclo (GOODFELLOW; BENGIO; COURVILLE, 2016).

$$\text{Atributo}_{\text{seno}} = \sin\left(\frac{2\pi \cdot \text{Valor}}{\text{Valormax}}\right) \tag{4.1}$$

$$\text{Atributocosseno} = \cos\left(\frac{2\pi \cdot \text{Valor}}{\text{Valormax}}\right) \tag{4.2}$$

O tratamento de dados faltantes será realizado antes da normalização: lacunas de até três dias serão preenchidas por interpolação linear e séries com falhas superiores serão removidas para evitar distorções estatísticas. Posteriormente, todas as variáveis serão normalizadas para a escala [0, 1] por meio da técnica *Min-Max Scaling*. A divisão dos dados em períodos Histórico (1980–1990) e Recente (pós-1991) seguirá a recomendação da climatologia operacional, que utiliza 1990 como marco para o cálculo de normais climatológicas (Organização Meteorológica Mundial (OMM), 2017). Em seguida, as séries serão estruturadas em janelas temporais contínuas, que servirão de insumos para os conjuntos de treino e teste.

Com os dados preparados, a fase de Modelagem consistirá na implementação das arquiteturas LSTM e TFT. Ambas serão treinadas nos dois regimes temporais definidos. Para garantir a comparabilidade técnica e eliminar vieses de implementação, ambos os modelos (LSTM e TFT) serão desenvolvidos utilizando a biblioteca *PyTorch* (via *framework PyTorch Forecasting*). Isso padroniza o motor de otimização e o cálculo de gradientes. Os hiperparâmetros — incluindo *learning rate*, *batch size* e número de *attention heads* — serão ajustados por meio de validação cruzada específica para séries temporais, utilizando a biblioteca Optuna, com o objetivo de minimizar o *RMSE* na janela de validação.

Definiu-se como vetor de entrada (X_t) para os modelos as séries diárias de precipitação, temperatura (mínima, média e máxima), evapotranspiração potencial e vazão defasada (*lookback window*), acrescidas do índice climático mensal ONI e das variáveis temporais cíclicas. Para atender à necessidade de quantificação de incertezas em eventos extremos, a saída do modelo (Y) não será uma estimativa pontual determinística, mas sim uma previsão probabilística via regressão quantílica. Os modelos serão configurados para estimar simultaneamente três quantis da distribuição de vazão futura:

- $\mathbf{P_{10}}$ (10º percentil): Cenário pessimista (crítico para detecção de secas severas).
- $\mathbf{P_{50}}$ (Mediana): Estimativa central (equivalente à previsão pontual).
- $\mathbf{P_{90}}$ (90º percentil): Cenário otimista (limite superior).

Essa abordagem permite construir intervalos de confiança ao redor da previsão, oferecendo suporte mais robusto à tomada de decisão na gestão de riscos hídricos.

Para responder à questão de pesquisa, adota-se a seguinte definição objetiva: Evento de Seca é qualquer período onde a vazão observada (y_t) for inferior à Vazão de Referência Q_{90} (valor superado em 90% do tempo na série histórica).

A fase de Avaliação utilizará um conjunto de teste unificado (a partir de 2011). Para capturar tanto o desempenho global quanto a precisão em estiagens, serão adotadas quatro métricas complementares:

1. Coeficiente de Eficiência de *Nash-Sutcliffe (NSE)*: Métrica padrão na hidrologia, utilizada para avaliar o ajuste geral do hidrograma. O NSE é mais sensível a valores de pico (cheias), indicando a capacidade do modelo de representar o comportamento global da bacia (AMANAMBU; MOSSA; CHEN, 2022):

$$\text{NSE} = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{4.3}$$

2. *Log-NSE* (*Nash-Sutcliffe* Logarítmico): Para responder especificamente ao objetivo de detecção de secas, será adicionado o Log-NSE. Ao aplicar o logaritmo nas vazões antes do cálculo, reduz-se a influência dos picos e aumenta-se a sensibilidade aos erros em vazões baixas, sendo a métrica ideal para validar a performance em estiagens:

$$\text{Log-NSE} = 1 - \frac{\sum_{i=1}^{n}(\ln y_i - \ln \hat{y}_i)^2}{\sum_{i=1}^{n}(\ln y_i - \overline{\ln y})^2} \tag{4.4}$$

3. *RMSE (Root Mean Squared Error)*: Mensura a magnitude média dos erros na unidade original da variável (m^3/s). Será calculado para a série completa e também condicionalmente para os períodos onde a vazão é inferior a Q_{90} (RMSE de Seca):

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{4.5}$$

4. Coeficiente de Determinação (R^2): Avalia a proporção da variância dos dados observados que é explicada pelo modelo, servindo como indicador de correlação linear:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{4.6}$$

Nestas equações, n representa o número de amostras, y_i a vazão observada, $\hat{y}_i$ a vazão prevista e $\bar{y}$ a média observada.

A fase final, equivalente à Implantação no contexto do *CRISP-DM*, será traduzida na organização, documentação e comunicação dos resultados. Essa etapa

incluirá a redação da monografia, a preparação dos materiais de apresentação e a disponibilização do código-fonte, assegurando reprodutibilidade e transparência.

Ao término da avaliação, pretende-se verificar se os modelos treinados com dados históricos — denominados Modelo do Passado — apresentam erros médios significativamente maiores ao prever eventos de seca no conjunto de teste, quando comparados aos modelos treinados com dados mais recentes, aqui denominados Modelo Atualizado. Essa análise permitirá testar a hipótese central da pesquisa, segundo a qual a não-estacionariedade reduz a capacidade preditiva de modelos de *deep learning*. Além disso, será avaliado se a arquitetura TFT apresenta desempenho superior ao LSTM em dados contemporâneos, considerando sua capacidade de integrar atributos estáticos e capturar relações temporais complexas.

Uma questão crítica neste estudo é assegurar que eventual degradação de desempenho do modelo seja, de fato, atribuível à não-estacionariedade (mudança no padrão dos dados) e não a limitações da arquitetura. Para mitigar esse risco, o experimento adota uma abordagem comparativa controlada.

A premissa lógica é que, se a hipótese de estacionariedade fosse válida, um modelo treinado com dados antigos (1980-1990) deveria ter desempenho estatisticamente similar a um modelo treinado com dados recentes (1991-2010) ao prever o mesmo conjunto de teste futuro (2011-2020).

Portanto, a degradação será mensurada pelo diferencial de erro (Δ_{erro}) entre os dois cenários. Se o Modelo Atualizado apresentar boa performance no teste, demonstra-se que a arquitetura é capaz de aprender. Consequentemente, se o Modelo Histórico falhar no mesmo teste, a falha é isolada como resultado direto do *dataset shift* (deslocamento da distribuição de probabilidade dos dados), confirmando o impacto da não-estacionariedade.

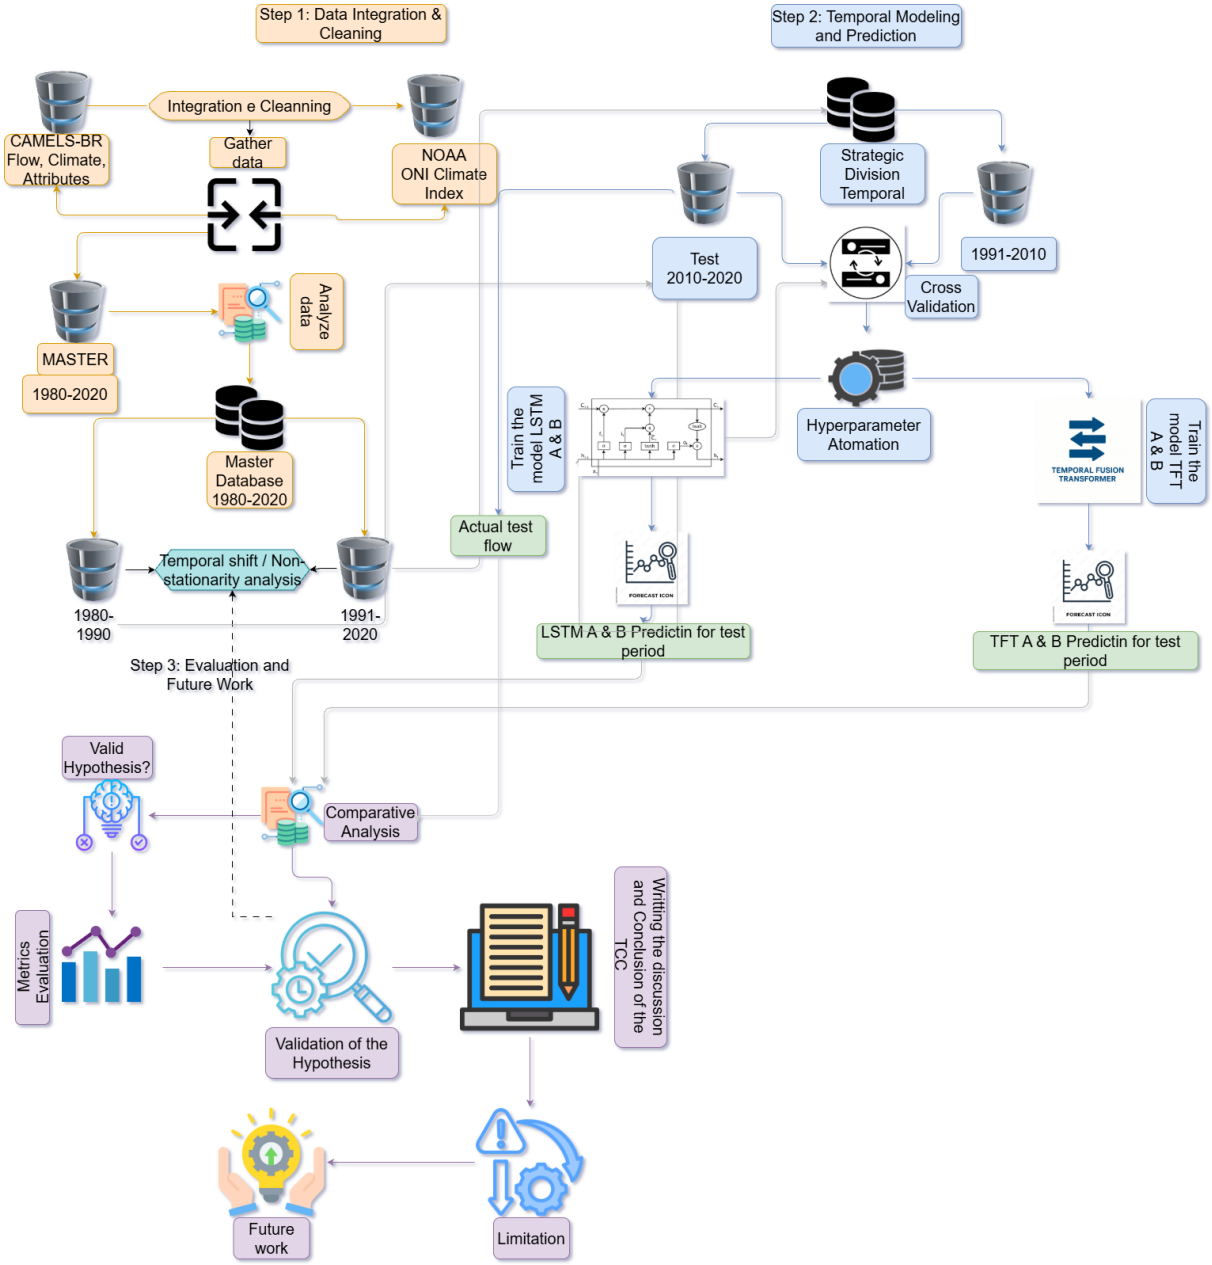

Figura 4.2 – Fluxograma geral da metodologia adotada, destacando as etapas do *CRISP-DM*.

O fluxo de trabalho ilustrado na Figura 4.2 detalha a execução metodológica da pesquisa, organizada em três macroetapas sequenciais:

1. *Step 1* (Integração e Limpeza): Consolidação das fontes de dados brutos (CAMELS-BR e índice ONI da NOAA) em uma base unificada, seguida da análise de não-estacionariedade que fundamenta a divisão temporal entre regimes "passado"e "recente".

2. *Step 2* (Modelagem Temporal): Divisão estratégica dos dados para o teste de estresse. Nesta etapa, ocorre o treinamento paralelo dos modelos LSTM e TFT em

dois cenários distintos (1980-1990 e 1991-2010), utilizando validação cruzada para otimização de hiperparâmetros.

3. *Step 3* (Avaliação e Validação): Comparação das previsões geradas pelos modelos "A"(histórico) e "B"(contemporâneo) contra os dados reais do conjunto de teste (2011-2020). É nesta fase que as métricas de erro (como *(Log-NSE)* são calculadas para validar a hipótese de que o *TFT* oferece maior robustez na detecção de secas.

5. CRONOGRAMA

Apresenta-se a seguir um cronograma de implementação que detalha as etapas para alcançar cada um dos objetivos propostos.

Tabela 5.1 – Cronograma detalhado do TCC 1 (2025) e TCC 2 (2026).

Tarefas	**2025**					**2026**						
	Ago.	**Set.**	**Out.**	**Nov.**	**Dez.**	**Jan.**	**Fev.**	**Mar.**	**Abr.**	**Mai.**	**Jun.**	**Jul.**
Entendimento do Problema	X	X	X									
Coleta dos Dados		X	X									
Entendimento dos Dados		X	X									
Escrita TCC 1		X	X	X	X							
Defesa TCC 1					X							
Revisão do TCC e Ajustes						X						
Preparação e Limpeza dos Dados (TCC 2)							X					
Implementação (Baseline LSTM)							X	X				
Implementação (Avançado TFT)								X	X			
Execução dos Experimentos e Otimização									X	X		
Análise Crítica dos Resultados										X	X	
Redação Final (TCC 2)										X	X	
Defesa do TCC 2												X
Correções Finais												X

REFERÊNCIAS BIBLIOGRÁFICAS

AMANAMBU, A. C.; MOSSA, J.; CHEN, Y. C. E. Hydrological drought forecasting using a Deep Transformer Model. *Water*, MDPI, v. 14, n. 17, p. 2623, 2022.

CHAGAS, V. B. P.; CHAFFE, P. L. B.; BLöSCHL, G. Climate and land management accelerate the Brazilian water cycle. *Nature Communications*, v. 13, n. 1, 2022.

CHAGAS, V. B. P. et al. CAMELS-BR: a large-sample dataset for hydrology and machine learning in Brazil. *Earth System Science Data*, Copernicus GmbH, v. 12, n. 3, 2020.

CHAPMAN, P. et al. *CRISP-DM 1.0: Step-by-step data mining guide*. [S.l.], 2000.

DONINELLI, T. L. et al. Previsão de vazões médias diárias com uso de redes neurais artificiais LSTM na bacia do Rio Apuaê-Inhandava. In: ABRH. *XXII Simpósio Brasileiro de Recursos Hídricos*. Florianópolis, SC, 2017.

FAYER, S. et al. Temporal Fusion Transformer for reservoir inflow forecasting in the Brazilian hydropower system. *Energy and AI*, Elsevier, v. 12, 2023.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. [S.l.]: MIT Press, 2016. <http://www.deeplearningbook.org>.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, MIT Press, v. 9, n. 8, p. 1735–1780, 1997.

KOYA, S. R.; ROY, T. Temporal Fusion Transformers for streamflow prediction: Value of combining attention with recurrence. *Journal of Hydrology*, Elsevier, v. 637, p. 131301, 2024.

LIM, B. et al. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, Elsevier, v. 37, n. 4, p. 1748–1764, 2021.

MARCUZZO, F. F. Bacia Hidrográfica do Rio Uruguai: Altimetria e áreas. In: ABRH. *XXII Simpósio Brasileiro de Recursos Hídricos*. Florianópolis, SC, 2017.

MILLY, P. C. D. et al. Stationarity is dead: Whither water management? *Science*, American Association for the Advancement of Science, v. 319, n. 5863, p. 573–574, 2008.

NOAA Climate Prediction Center. *Oceanic Niño Index (ONI)*. 2025. <https://www.cpc.ncep.noaa.gov/products/analysis_monitoring/ensostuff/ONI_v5.php>. Acessado em 29 de setembro de 2025.

Organização Meteorológica Mundial (OMM). *WMO Guidelines on the Calculation of Climate Normals*. Genebra, Suíça, 2017. WMO-No. 1203.

REICHSTEIN, M. et al. Early warning of complex climate risk with integrated artificial intelligence. *Nature*, Nature Publishing Group, v. 599, n. 7883, p. 39–41, 2021.

ROSA, I. M. D. et al. Widespread streamflow decline in Brazil linked to deforestation. *Nature Communications*, Nature Publishing Group, v. 13, n. 1, 2022.

VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2017. p. 5998–6008.